

# DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning ([arxiv](#))

## Key Highlights

### 問題

- **這篇論文旨在解決什麼問題？** 這篇論文旨在通過強化學習（Reinforcement Learning, RL）提升大型語言模型（Large Language Models, LLMs）的推理能力，特別是針對實現測試時的擴展和推理表現，達到與OpenAI的o1系列模型相當的挑戰。
- **現有的方法有哪些，這些方法有什麼局限性？** 現有的方法包括基於過程的獎勵模型，強化學習方法及搜尋算法（如蒙特卡洛樹搜尋，Beam Search）。然而，這些方法的推理性能並未能達到與OpenAI的o1系列模型相當的水平。傳統方法極度依賴於大量的監督數據，這些數據的收集非常耗時。

### 解決方案

- **這篇論文提出了什麼解決方案？** 論文提出兩個主要方法：(1) DeepSeek-R1-Zero - 沒有監督微調，直接應用強化學習於基礎模型，(2) DeepSeek-R1 - 包含冷啟動數據的多階段培訓管道，包括RL、SFT及額外的RL階段。
- **這個想法的靈感來自哪裡？是否受其他論文影響？** 該方法的靈感來自於OpenAI o1系列在推理時擴展的成功，通過思維鏈推理。這項工作基於Group Relative Policy Optimization (GRPO) 並探討了純RL訓練的途徑，避免依賴監督數據。
- **什麼理論基礎支持這種方法？** 該方法使用GRPO算法進行成本效益良好的RL訓練，基於規則的獎勵系統（準確性和格式獎勵），以及一種能在RL過程中自然進展的結構化樣板方法，沒有內容特定的偏見。

### 實驗

- **實驗表現如何？** DeepSeek-R1在多項標杆測試中達到與OpenAI-o1-1217相當的表現：79.8% (AIME 2024)，97.3% (MATH-500)，96.3百分位 (Codeforces)。DeepSeek-R1-Zero在AIME 2024中的表現從15.6%顯著提升至71.0%。精簡的小模型同樣展示了強勁的表現，7B模型在AIME 2024中達到55.5%。
- **該方法有哪些限制或假設？** 方法假設基於規則的獎勵系統足夠，並避免使用神經獎勵模型，因為擔心獎勵投機問題。它需要大量的計算資源來進行大規模RL訓練，並且對提示詞設計敏感。

## 創新

- **這篇論文有什麼重要或新穎的發現？** 論文證明推理能力可以純粹通過RL而非監督微調來實現，展示了如自我驗證和反思等複雜行為的自然發展。論文有效地將大型模型中的推理模式蒸餾到小型模型，而不是直接將RL應用於小型模型。

## 評論 / 評析

- **這篇論文有什麼局限性？** 論文承認了一些局限性：語言混合問題，非推理任務表現相比DeepSeek-V3有所下降，對提示詞設計敏感，並且由於評估時間限制，在軟體工程任務上的改進有限。
- **這篇論文是否有效支持其主張？** 論文通過多重標杆測試提供了全面的實驗驗證，並包含與強勁基線模型的比較。然而，一些結果依賴於官方報導而非直接評估，且論文缺乏與傳統方法相比的計算成本和訓練效率的詳細分析。

## Comprehensive Analysis

No section notes.

## References

No references found.