DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning (arxiv)

Key Highlights

問題

- **這篇論文旨在解決什麼問題？** 這篇論文旨在開發具增強推理能力的大型語言模型，以匹配OpenAI的o1系列模型的性能。具體挑戰是通過增加連鎖思維推理過程的長度來實現有效的測試時刻擴展。

- **現有的方法有哪些，並且他們有什麼限制？** 現有方法包括基於過程的獎勵模型、強化學習和如蒙特卡羅樹搜索和束搜索的搜索算法。然而，這些方法都未能實現與OpenAI的o1系列模型相媲美的通用推理性能。傳統方法還嚴重依賴於大量的有監督數據，這些數據的收集非常耗時。

解決方案

- **這篇論文提出了什麼解決方案？** 這篇論文提出了兩個模型：(1) DeepSeek-R1-Zero，通過純強化學習訓練，無需有監督的微調，(2) DeepSeek-R1，包括在RL之前使用冷啟動數據的多階段訓練。他們使用Group Relative Policy Optimization (GRPO)作為RL框架，並採用基於規則的獎勵。

- **這個想法的靈感來自哪裡？是否受其他論文影響？** 這個方法的靈感來自OpenAI的o1系列在推理時間擴展上的成功，和之前在推理任務中使用強化學習的工作。這個方法基於GRPO，並探討了在不依賴於大量有監督數據的情況下，純RL的可行性。

- **哪些理論基礎支持這個方法？** 這個方法基於強化學習理論，特別是使用GRPO，其從群體分數而非需要評論者模型中估計基線。獎勵系統結合了準確性獎勵（基於規則的驗證）和格式獎勵，以指導優化方向。

實驗

- **實驗效果如何？** DeepSeek-R1達到與OpenAI-o1-1217相當的性能：AIME 2024得分79.8%，MATH-500得分97.3%，Codeforces排名96.3百分位，以及GPQA Diamond得分71.5%。DeepSeek-R1-Zero單獨達到了AIME 2024得分71.0%，相當於OpenAI-o1-0912的性能。

- **這種方法有什麼限制或假設？** 這種方法假設在訓練獎勵方面可以使用基於規則的驗證，需要大量計算資源以進行大規模的RL，並且對提示敏感。該方法在早期階段還面臨語言混合和可讀性差的挑戰。

創新點

- **這篇論文提出了哪些重要或新穎的發現？** 主要創新包括：(1) 首次展示推理能力可以完全通過RL開發而無需監督微調，(2) 發現了模型自發學會分配更多思考時間和反思行為的"靈感時刻"，(3) 將推理能力成功蒸餾到較小的模型，在顯著更少的參數下實現強大性能。

評論 / 批判

- **這篇論文有什麼限制嗎？** 論文承認了幾個限制：與DeepSeek-V3相比，整體能力在函數調用和複雜角色扮演方面有差距，在非英語/中文查詢中存在語言混合問題，對提示敏感（少樣本提示會降低性能），並且由於評估時間限制，在軟件工程任務上的改進有限。

- **論文是否有效證明其主張？** 是的。該論文在多個基準上提供了全面的實驗驗證，提出了詳細的消融研究以比較蒸餾與RL方法，並誠實地討論了不成功的嘗試（PRM, MCTS）。結果展示了明顯的性能提升，並且該方法詳細記錄了具體的技術細節。

Comprehensive Analysis

No section notes.

References

No references found.