

Test-Time Scaling with Reflective Generative Model ([arxiv](#))

Key Highlights

問題

- 這篇論文旨在解決什麼問題？
 - 論文旨在解決大語言模型在測試時縮放（Test-Time Scaling, TTS）中的低效問題，特別是現有外部TTS方法使用的分別的過程獎勵模型（Process Reward Models, PRMs）所帶來的高計算成本和昂貴的過程級別註釋。
- 現有的方法有哪些，並且它們有哪些局限性？
 - **內部TTS**：使用長鏈思維（Chain-of-Thought, CoT）進行序列推理，但存在誤判推理過程的問題，即正確答案可能有不正確的推理步驟。
 - **外部TTS**：使用獨立的PRM進行軌跡選擇，通過Best-of-N採樣、束搜索或樹搜索方法。局限性包括：(1) 來自獨立PRM參數的額外計算，(2) PRM訓練所需的昂貴的過程級別註釋，(3) 非策略訓練限制了區分目標LLM輸出的能力。

解決方案

- 這篇論文提出了什麼解決方案？
 - 論文提出一種“反思生成形式”，在策略模型和PRM之間共享骨幹網路，使用特定任務頭進行推理軌跡預測和評分。這只引入了53M的額外參數來進行軌跡評分，並通過自我監督過程獎勵模型（SPRM）消除了對過程級別註釋的依賴。
- 這個想法受到什麼啟發？它受到其他論文的影響嗎？
 - 這個方法受到OpenAI的o3模型TTS技術和現有PRM工作的分析啟發（Lightman et al., 2023）。統一界面概念解決了當前外部TTS方法中發現的計算低效問題。
- 有什麼理論依據支持這個方法？
 - 這個方法使用幾何平均來進行軌跡評分，使用動態加權處理噪音監督的自我監督SPR損失，並通過參數共享實現策略模型和獎勵模型之間的在策略優化。

實驗

- 實驗效果怎麼樣？
 - MetaStone-S1-32B在只有32B參數情況下取得了可比於OpenAI o3-mini的性能。具體改進包括：在AIME24上取得18.6/15.5/5.3分，在AIME25上取得10.5/7.4/3.1分，分別對應於1.5B/7B/32B規模，相比基線模型。
- 這個方法有哪些局限性或假設？
 - 當推理長度超過基線的32倍時，性能改進會放緩。MCTS集成顯示出潛力，但由於計算開銷，表現不如Best-of-N方法。該方法假設幾何平均能有效聚合步驟級別的得分。

創新

- 這篇論文有什麼重要或新穎的發現？
 - **統一界面**：首次在策略模型和PRM之間共享骨幹，顯著減少了參數開銷。
 - **自我監督學習**：通過SPRM消除了過程級別註釋的需求，僅通過結果監督。
 - **靈光一現發現**：識別出模型學會區分正確和不正確推理軌跡的特定訓練點。
 - **縮放律分析**：顯示了性能與計算預算對數之間的正相關。

評論/批評

- 這篇論文有什麼局限性？
 - 對於失敗案例和邊界條件的分析有限。相比於其他方法，幾何平均聚合方法缺乏理論上的支持。MCTS集成結果為初步結果，表現不及簡單方法。
- 這篇論文是否有效地證實了它的主張？
 - 是的，論文提供了多個基準測試、不同規模和與開源及閉源模型比較的全面實驗驗證。消融研究有效展示了每個組件的貢獻，並且縮放律分析提供了該方法行為的理論見解。

Comprehensive Analysis

No section notes.

References

No references found.