

One Token to Fool LLM-as-a-Judge ([arxiv](#))

Key Highlights

問題

- 這篇論文旨在解決什麼問題？

- 論文針對在強化學習可驗證獎勵 (RLVR) 中使用的生成獎勵模型 (LLMs-as-judges) 的關鍵漏洞，即簡單的對抗模式稱為"主鑰匙"，能觸發誤判的正向獎勵。
- 這些"主鑰匙"包括非文字符號（例如 ":", "."）和推理開頭語（例如 "思考過程："，"讓我們逐步解決這個問題"），即使在語義上毫無意義，也能持續獲得正面評價。

- 現有的方法是什麼，有哪些局限性？

- 基於規則的獎勵機制使用預先定義的標準，但難以處理不同形式的數學等價答案，且無法應付開放式回應。
- 現有的生成獎勵模型（包括 GPT-4o, Claude-4, 專用驗證器等）易受表面操控，誤判率高達 80-90%。
- 當前作為法官的LLM系統在面對最小的對抗輸入時缺乏穩健性，破壞了RLVR訓練管道的完整性。

解決方案

- 這篇論文提出什麼解決方案？

- 一種通過截斷模型輸出僅保留第一句（通常是推理開頭語）來構造類似對抗攻擊訓練樣本的數據增強策略。
- 這些截斷的回應被標註為負樣本並加入訓練數據中。
- 使用這個增強數據訓練一個新的生成獎勵模型稱為 Master-RM。

- 這個想法的靈感來自哪裡？是否受其他論文啟發？

- 靈感來自觀察到RLVR訓練崩潰的現象，即策略模型學會生成短的推理開頭語並持續獲得正向獎勵。
- 基於 Su et al. (2025) 的訓練設置，並用 20k 的反駁客範例擴展了他們的 160k 數據集。

- 這個方法有什麼理論基礎支持？

- 該方法針對LLM混淆推理結構指標與實際解決問題內容的系統性弱點。

- 使用交叉熵損失的監督微調教導模型區分有意義的解決方案和表面的推理開頭語。

實驗

• 實驗效果如何？

- Master-RM 在測試的所有 "主鑰匙" 和數據集上達到接近零的誤判率 (0.0-2.9%)。
- 保持 100% 的解析成功率和 0.96 的一致性，這是所有評估模型中最高的。
- 儘管僅針對一小部分負樣本進行訓練，對未見過的攻擊和數據集展現出強大的泛化能力。

• 這個方法有哪些局限性或假設？

- 該方法主要關注推理開頭語，可能無法解決推理過程中或結尾處出現的推理提示。
- 評估依賴於作為 "黃金標準" 的 GPT-4o，儘管其本身也易受主鑰匙攻擊。
- 需要仔細構建負樣本，可能需要針對不同領域適應。

創新

• 這篇論文有哪些重要或新的發現？

- 首次系統地識別和評估 "主鑰匙" 漏洞，涵蓋多樣的 LLM、數據集和提示格式。
- 發現該漏洞甚至影響了最先進的專有模型，如 GPT-4o 和 Claude-4。
- 展示了非單調的縮放行為，即漏洞隨模型大小變化的不確定性。
- 首次提出了專為 RLVR 設計的生成獎勵模型的有效緩解策略。
- 引入嵌入方法自動生成新的對抗性 "主鑰匙"。

評論/批判

• 這篇論文有什么限制？

- 評估主要依賴於作為真值的 GPT-4o，儘管已確認其自身的漏洞。
- 數據增強策略相對簡單，可能無法泛化到更複雜的攻擊模式。
- 對計算成本或訓練效率影響的分析有限。
- 該方法專注於一種特定的漏洞，可能無法解決其他形式的獎勵駭取。

• 這篇論文有有效證實其主張嗎？

- 是的，通過多個模型、數據集和語言提供了全面的實證證據。
- 通過崩潰的 RLVR 訓練示例展示了明顯的實際影響。
- 展示了幾乎零誤判率的有效緩解，同時保持了總體性能。
- 然而，對這些漏洞存在的理論理解可以更深入，對抗演變中的攻擊策略的長期穩健性仍不明確。

Comprehensive Analysis

Abstract

結構化摘要

- 本論文識別了用於評估答案質量的生成性獎勵模型（LLMs-as-judges）中的關鍵漏洞，這些模型在強化學習系統中使用。
- 生成性獎勵模型容易被表面上的文本操作所愚弄。
- 簡單的添加，如標點符號（“:”、“.”）或常見的推理短語（“思考過程：”，“讓我們一步步解決這個問題”），可能會觸發虛假正向獎勵。
- 這種漏洞在不同的LLMs、數據集和提示格式中廣泛存在。
- 這些弱點對依賴生成性獎勵模型的機器學習範式，如拒絕採樣、偏好優化和具有可驗證獎勵的強化學習（RLVR），構成了嚴重風險。
- 作者開發了一種數據增強策略來訓練更強健的獎勵模型。
- 他們創建並發布了一個改進的生成性獎勵模型，對這些操作有更好的抵抗能力。
- 本研究揭示了現有LLM-based評估方法中的基本可靠性問題，並提供了證實此問題的實驗證據和提高穩健性的實際解決方案。

Introduction

摘要

- 本介紹部分確立了一個基本原則，即在機器學習中，特別是針對訓練後方法，**評估比生成更容易**。
- 作者追溯了從這一原則演變到目前使用**大型語言模型 (LLMs) 作為裁判**的過程。
- 大型語言模型可以通過排名回答或分配質量分數來評估回應，並且與人工評價有超過80%的一致性。
- 接下來介紹了主要焦點：**在具有可驗證獎勵的強化學習 (RLVR)中，大型語言模型作為生成性獎勵模型**。
- 這種方法在以下方面超越了傳統的基於規則的獎勵功能：
 1. 使用大型語言模型將策略模型生成的答案與參考答案進行比較。
 2. 提供獎勵信號來指導模型訓練。
 3. 使RLVR能夠處理**開放式和非結構化的輸出**，不僅限於需要結構化答案的領域。
- 強調的關鍵創新是利用大型語言模型的生成能力，使強化學習更具靈活性和更適用於涉及複雜、非結構化回應的廣泛推理任務。

圖像摘要

- 未包含圖像摘要。

'A widely recognized principle in many post-training methods (Ouyang et al., 2022) is that evaluating a response is often easier than generating one (Leike et al., 2018).'

在許多訓練後方法中，眾所周知的一個原則是評估一個回應通常比生成一個回應更容易。

'recent studies have proposed using LLMs as generative reward models in reinforcement learning with verifiable rewards (RLVR) (Luong et al., 2024; Lambert et al., 2024; Guo et al., 2025), aiming to replace traditional rule-based reward functions that often lack flexibility'

最近的研究提出將大型語言模型用作具有可驗證獎勵的強化學習（RLVR）中的生成性獎勵模型，旨在取代通常缺乏靈活性的傳統基於規則的獎勵功能。

'By leveraging the generative capabilities of LLMs, this approach allows RLVR to move beyond domains with well-structured answers, enabling its use in broader reasoning tasks involving open-ended or unstructured outputs.'

通過利用大型語言模型的生成能力，這種方法使得RLVR能超越具有結構良好的答案的領域，能夠用於涉及開放式或非結構化輸出的更廣泛的推理任務。

Related Work

- 本相關工作部分涵蓋了三個主要領域，來自驗證器獎勵的強化學習（RLVR）：
- **1. 基於規則的獎勵：**這些利用預定義的標準來評估大型語言模型（LLM）的輸出，最初用於安全應用，但現在同樣有效於推理任務。
- 它們從二元信號演變為連續的[0,1]值，以提供更細微的反饋，但在應對不同形式的數學等價答案方面仍然存在困難。
- **2. 生成性獎勵（LLM 作為評審）：**這種方法通過提示使用LLM本身來評估響應，解決了基於規則的方法在識別等價答案和評估開放性響應方面的限制。
- 這些方法可以結合先進的技術如連鎖思維推理。
- **3. 已知的漏洞：**之前的研究指出了LLM作為評審系統的幾個弱點，包括對回應順序的敏感性、易受對抗性短語的影響，以及易被無意義的輸入所欺騙。
- 黃等人（2025年）的最新研究顯示，數學推理模型可以被空符號和無意義的回應所誤導。
- **作者的貢獻：**本研究的獨特之處在於，既調查了非文字符號攻擊，也研究了一種新的類別「推理開頭」，將評估範圍擴展到一般推理任務，測試了包括GPT-4o在內的更大模型，並提出了第一個數據增強策略，以減輕生成性獎勵模型中的這些漏洞。

"While rule-based rewards offer computational efficiency, they struggle to recognize mathematically equivalent answers expressed in different forms and cannot effectively evaluate open-ended responses in general reasoning scenarios (e.g., short-answer questions)."

儘管基於規則的獎勵提供計算效率，但它們難以識別以不同形式表達的數學上等價的回答，並且無法有效地評估一般推理場景中的開放式回答（例如，簡答題）。

"In this work, we systematically investigate the vulnerabilities of generative reward models, which persist even with the use of advanced inference-time techniques."

在這項工作中，我們系統地調查生成獎勵模型的漏洞，即使使用先進的推理技術，這些漏洞仍然存在。

"In contrast, our work investigates both non-word symbol attacks and a new class of attacks named reasoning openers, which usually lead to more severe false positive judgments. Furthermore, we expand the evaluation beyond mathematics to a broader set of general reasoning tasks and reveal vulnerabilities in large-scale models, including GPT-4o."

相比之下，我們的研究調查了非單詞符號攻擊和被稱為推理開端的一類新攻擊，這些攻擊通常導致更嚴重的錯誤判斷。此外，我們將評估擴展到數學以外的一般推理任務，並揭示包括GPT-4o在內的大規模模型的漏洞。

Methodology

- 本節提出了一個解決強化學習中的可驗證獎勵 (RLVR) 模型漏洞的框架。
- 作者識別了兩個主要貢獻：

問題識別 - "主鑰匙"攻擊： - 作者發現，RLVR系統中的LLM判斷容易受到"主鑰匙"攻擊，即是誘發錯誤正面獎勵的簡單對抗模式。 - 這些模式分為兩類： - 非單詞符號，例如標點符號。 - 推理開篇，例如"讓我們逐步解決這個問題"，看似有意義但並未提供實質性內容。 - 此漏洞影響了最先進的模型，包括GPT-4o和Claude-4，破壞了RLVR訓練管道的完整性。

解決方案 - 主獎勵模型 (Master-RM)： - 作者通過增加對抗示例來增強訓練數據，開發了一個強健的獎勵模型。 - 他們創建了2萬個含推理開篇的負樣本（來自思路鏈回應的第一句）並標記為無效。 - 通過將這些數據與16萬原始訓練實例結合，並在 Qwen2.5-7B-Instruct模型上進行微調，打造出Master-RM。 - 結果顯示，該模型在

多個基準上對主鑰匙攻擊的偽陽性率接近於零，展示了有針對性的數據增強能顯著提高獎勵模型的穩健性。

- 此工作凸顯了當前RLVR系統中的一個關鍵安全漏洞，並通過對抗訓練提供了一個實用的防禦機制。

"In this work, we identify a family of adversarial patterns, termed "master keys". When used as responses r , these patterns can surprisingly trigger positive judgments from a wide range of LLM judges, even though they are semantically meaningless for solving the task."

"This reveals a critical and underexplored vulnerability in the core mechanics of reward modeling: the verifier, designed to filter out invalid or incorrect answers, can be manipulated by trivial, superficial content, resulting in false positives."

"Experimental results show that this model generalizes remarkably well: despite being trained on only a small fraction of targeted negative examples, it achieves near-zero (if not zero) false positive rates on all tested "master keys" across all five large-scale, multi-domain benchmarks."

在這項工作中，我們識別出一系列對抗模式，稱為「萬能鍵」。當用作回應 r 時，這些模式會出乎意料地從大量 LLM 評審中觸發正面判斷，儘管它們在解決任務上語義上無意義。

這揭示了獎勵建模核心機制中的一個關鍵且未經充分探索的漏洞：設計用於過濾無效或錯誤答案的驗證器可以被微不足道的表面內容操縱，導致誤報。

實驗結果表明，這個模型概括能力非常好：儘管只在一小部分目標負面的例子上進行了訓練，它在所有經測試的「萬能鍵」上達到接近零（如果不是零的話）誤報率，涵蓋了所有五個大規模多領域基準。

Experiments

摘要

此部分描述了使用稱為「主鍵」的最小輸入來評估基於LLM的獎勵模型（RMs）對「表面黑客攻擊」的脆弱性之實驗設置。

測試模型： - 專

評估基準： - 一般推理：多主題RLVR和NaturalReasoning數據集 - 數學推理：GSM8K（小學）、MATH（高中）和AIME（高級奧林匹克問題）

主要研究問題： - 實驗研究這些最小、非解題輸入如何欺騙獎勵模型並給予正面評分（假陽性） - 檢查模型大小效應和語義相似性模式等因素 - 測試先進的提示技術能否減輕這些脆弱性

為了全面評估基於LLM的RM對表面攻擊的脆弱性，我們評估了廣泛的模型、數據集和對抗模式。

在評估中，我們使用最小化的『主密鑰』，雖不提供實際解決方案，卻能經常引起LLM評審的正面回饋。包括：

- 非單詞符號：『』（一個空格）、' '、' '、' '。
- 推理開頭語：『思考過程：』、『讓我們一步步解決這個問題。』、『解決方案』及其多語言版本，包括『解』（中文）、『かいせつ』（日文）和『Respuesta』（西班牙文）。

值得注意的是，我們的主RM經過特殊訓練，對抗黑客攻擊表現出強韌性，並在所有評估中始終保持幾乎為零的誤報率。

Conclusions

結論

- 生成獎勵模型作為規則基礎的獎勵函數替代品在言語強化學習 (RLVR) 中越來越受歡迎。
- 這些模型具有顯著的脆弱性。
- 研究顯示，這些模型容易被涉及非單詞符號和推理開端的簡單攻擊所欺騙，導致誤判獎勵。
- 這種脆弱性在多個數據集、提示，甚至是最先進的模型如 GPT-4o 和 Claude-4 中都存在。
- 這些獎勵系統在各種機器學習範式（拒絕採樣、偏好優化、RLVR）的廣泛採用，凸顯了建立更強大可靠的基於LLM的評估方法的迫切需求。
- 作者提出了一個簡單的緩解策略。
- 他們呼籲在未來的應用中採用更強的評估框架。

References

No references found.